


Embeddings (Vectores Densos de Deep Learning)

Linette, Esteban, Eric, Christopher, JP

Embeddings - Linette


La palabra o conjunto de datos se transforma en una matriz de n-dimensiones, donde cada dimensión representa alguna característica del dato procesado. Se basa en las distancias, donde los puntos más cercanos son más probables de tener significados parecidos o pertenecientes al mismo contexto.




Su ventaja sobre métodos como One-Hot embedding es que los embeddings son capaces de capturar el significado semántico (significado) y contexto de la palabra.

Son bastante utilizados en herramientas como los buscadores semánticos y de recomendación de marketplace.

Compute Embeddings



Embeddings Space



1. ¿Cuál es la mecánica?

Un embedding toma un término y lo convierte en una lista de números (por ejemplo, coordenadas).

Ejemplo de Negocio

Buscadores semánticos e *Amazon* c...
 Tiendas como Amazon c...
 de productos y las consu...
 vectores. Si buscas "cami...
 sistema encuentra prenc...
 significado aunque no co...
 exactas. [1, 2, 3]

¿Ventaja competitiva?

no sólo las palabras

Embeddings (Chris)

A cada palabra se le asigna una coordenada dentro de un espacio dimensional (vectores de cientos o miles), pudiendo relacionar palabras dependiendo de su cercanía (agrupación), siendo mejor que One-Hot Encoding ya que reconoce el contexto de las palabras

Al poder relacionar y agrupar puede automatizar la organización de los tickets de soporte al cliente.

Embeddings - Eric


5

Ejemplo

El campo texto abierto de un buscador y la variable categorica de los resultados en un motor de busqueda.

Ventaja

Es mejor que One Hot-Encoding porque captura el contexto de la palabra y no crea vectores gigantes .



Embeddings

Esteban

Es básicamente CBOW y Skip-gram

Álgebra de conceptos: operar productos como números.



Entienden Contexto, no solo palabras sueltas:

El estándar actual en IA (NLP)⁶ para convertir texto en vectores densos. Cada concepto se ubica en un mapa de 768 a 3,072 dimensiones: las ideas similares quedan cerca. matemáticamente

$$\text{Vector}(\text{Croquetas para gato}) - \text{Vector}(\text{Gato}) + \text{Vector}(\text{Perro}) \approx \text{Vector}(\text{Alimento para perros})$$

Texto	Embedding	Geometría
Alimento para perros	[0.85, -0.12, 0.91, ...]	Vecinos
Croquetas para gatos	[0.82, -0.15, 0.88, ...]	Vecinos
Laptop	[-0.71, 0.94, -0.33, ...]	Lejano